

Carrión por síntomas — Red Neuronal vs. Árbol (dataset simulado)

Explicación del código, paso a paso (material de exposición)

Inteligencia Artificial · UNTELS · Caso: enfermedad de Carrión (MINSA) · Comparativa Red Neuronal vs. Árbol de Decisión

DATASET SIMULADO con fines educativos. No proviene del MINSA ni de ninguna fuente real: los datos abiertos peruanos de vigilancia no publican síntomas por paciente. Aquí se GENERAN sintéticamente según los criterios clínicos de la literatura médica, para comparar ambos modelos sobre variables (síntomas) que sí distinguen bien cada fase.

Este documento explica el código del caso «**Carrión por síntomas**»: un formulario donde se marcan síntomas y los modelos predicen la fase **AGUDA** (Fiebre de la Oroya) o **ERUPTIVA** (Verruga Peruana). Se comparan Red Neuronal y Árbol de Decisión, igual que en los otros casos.

1. Generación del dataset sintético

```
rng = np.random.RandomState(42); N = 6000
SINTOMAS = ["fiebre_alta", "palidez_anemia", "fatiga_debilidad", "dolor_cabeza_cuerpo",
            "ictericia", "ganglios_hinchazon", "verrugas_piel", "sangrado_lesiones"]
# Probabilidad de cada síntoma SEGÚN la fase (de la clínica):
P_AGUDA = {"fiebre_alta":.92, "palidez_anemia":.90, ... "verrugas_piel":.05}
P_ERUPTIVA = {"fiebre_alta":.12, "palidez_anemia":.16, ... "verrugas_piel":.90}
for fase in fases:
    # fase sorteada 50/50
    P = P_AGUDA if fase=="AGUDA" else P_ERUPTIVA
    fila = {s: int(rng.rand() < P[s]) for s in SINTOMAS} # Bernoulli(P)
```

Para cada paciente se sortea su fase y luego cada síntoma se activa (1) o no (0) con una probabilidad que depende de la fase. Por ejemplo, la fiebre aparece en el 92% de los casos agudos pero solo en el 12% de los eruptivos; las verrugas, al revés. Así el dataset refleja la clínica real sin ser datos reales.

Se añade ~8% de ruido (voltear un síntoma al azar) para simular presentaciones atípicas y evitar que la clasificación sea trivial.

2. Preparar entradas y dividir train/test

```
X = df[SINTOMAS].values.astype(float) # 8 síntomas (0/1)
Y = (df["fase"] == "ERUPTIVA").astype(int).values # AGUDA=0, ERUPTIVA=1
Xtr,Xte,ytr,yte = train_test_split(X,Y, test_size=.2, stratify=Y, random_state=42)
```

Las 8 columnas de síntomas son la entrada; la fase es el objetivo. Reservamos 20% para prueba. Como los síntomas ya son 0/1, **no hace falta normalizar** (ni para el árbol ni para la red).

3. Árbol de Decisión

```
from sklearn.tree import DecisionTreeClassifier
arbol = DecisionTreeClassifier(criterion="entropy", random_state=42).fit(Xtr, ytr)
print("train:", arbol.score(Xtr,ytr), " test:", arbol.score(Xte,yte))
```

El árbol aprende reglas del tipo «¿tiene verrugas? → ERUPTIVA». Con síntomas tan informativos, sus reglas son cortas y certeras.

4. Red Neuronal (8 → 32 → 32 → 1)

```
red = keras.Sequential()
red.add(layers.Dense(32, input_dim=8, activation="relu"))
red.add(layers.Dense(32, activation="relu"))
red.add(layers.Dense(1, activation="sigmoid"))
red.compile(loss="binary_crossentropy", optimizer="adam", metrics=["accuracy"])
red.fit(Xtr, ytr, epochs=200, batch_size=64, verbose=0)
```

Misma arquitectura que los otros casos, pero con **8 entradas** (una por síntoma). La capa final sigmoide da la probabilidad de ERUPTIVA.

5. Predicción de un caso por síntomas

```
# [fiebre,palidez,fatiga,dolor,ictericia,ganglios,verrugas,sangrado]
caso_sistemico = np.array([[1,1,1,1,0,0,0,0]]) # -> AGUDA
caso_cutaneo    = np.array([[0,0,0,0,0,0,1,1]]) # -> ERUPTIVA
arbol.predict(caso_cutaneo) # 1 (ERUPTIVA)
red.predict(caso_cutaneo)[0][0] >= 0.5 # True (ERUPTIVA)
```

Un paciente con síntomas sistémicos (fiebre, anemia, fatiga) es clasificado como AGUDA por ambos modelos; uno con verrugas que sangran, como ERUPTIVA. Es el mismo razonamiento que hace el formulario web.

Resultado e interpretación

Aquí **ambos modelos alcanzan ~98% en prueba** y coinciden casi siempre. Esto contrasta con el caso basado en datos del MINSA (edad, sexo, zona, fecha), donde el árbol sobreajustaba y la red generalizaba mejor.

Lección de la comparativa: la **calidad de las variables importa tanto o más que el modelo**. Con predictores realmente informativos (síntomas), Red Neuronal y Árbol rinden parecido; las diferencias entre modelos se notan sobre todo cuando los datos son débiles o ruidosos. (Recordatorio: dataset simulado, no apto para diagnóstico real.)